

Harness do Projeto

> **Objetivo Principal:** Sistema de "Monitoria de Chamadas" baseado em IA. Transcreve áudios de atendimento ao cliente usando Whisper (local ou Cloud Run) e os avalia contra critérios de qualidade utilizando Gemini (Google), fornecendo notas (QA Score) e feedback através de um Dashboard web interativo.

Arquitetura

- **Stack Tecnológico:**
- **Backend:** Python, FastAPI, Uvicorn (Assíncrono com BackgroundTasks)
- **Frontend:** React, Vite, TailwindCSS (Identidade Visual Coherence.AI), Lucide Icons
- **IA (Transcrição):** faster-whisper (PyTorch, CTranslate2)
- **IA (Avaliação):** Google Generative AI (Gemini 1.5 Pro)
- **Integrações (APIs/Bancos):**
- Banco Local SQLite (`monitoria.db`)
- MiniMax M3 API (para extração de QA e feedback, substituindo Gemini)
- **Variáveis de Ambiente Necessárias (GCP Cloud Run):**
- `MINIMAX\_API\_KEY`: Chave para inferência do LLM.
- `PYTHONUNBUFFERED=1`: Para garantir logs em tempo real (print flush).
- `OMP\_NUM\_THREADS=2`: Para evitar crash/concorrência excessiva do faster-whisper (CTranslate2) nas CPUs do Cloud Run.
- **Fluxo de Dados Principal:**
- 1. Frontend (React) faz upload de um arquivo de áudio para `POST /api/upload`.
- 2. Backend (FastAPI) cria um registro no SQLite e enfileira um BackgroundTask de processamento para não travar a UI.
- 3. A UI monitora `GET /api/calls` via short-polling (a cada 1 ou 2 segundos).
- 4. O Background Task executa `Transcriber` (Whisper), atualiza o status.
- 5. O Background Task executa `Evaluator` (Gemini), atualizando o status e nota final.
- 6. Frontend recebe "Concluído" e a interface atualiza com o Score de QA (Verde, Amarelo, Vermelho) e esconde a barra de progresso em troca do detalhe.

Estrutura de Diretórios

- `/core`: Lógicas isoladas de IA (`transcriber.py`, `evaluator.py`).
- `/frontend`: Aplicação React/Vite isolada (dist build é servido estaticamente no backend FastAPI).
- `api.py`: Roteador principal FastAPI e BackgroundTasks.
- `Dockerfile`: Arquivo responsável pela construção da infraestrutura no GCP (Cloud Run).
- `/docs`: Documentação técnica essencial.

Autenticação e Segredos

- O projeto consome segredos utilizando o arquivo global `secrets\_manager.py` (banco cofre). A variável `GEMINI\_API\_KEY` é extraída de maneira segura para inferência, evitando credenciais hardcoded.

Histórico de Erros e Resoluções

- **Erro de Falhou na Interface:** Ao enviar áudios, a interface do usuário exibia o status Falhou após um longo tempo aguardando. Isso ocorreu porque o processo do Whisper no Cloud Run consome tempo substancial de CPU e a interface assumia um timeout ou um erro prematuro, apesar de o servidor continuar processando e salvar os

resultados corretamente no SQLite (monitoria_ia.db). Foi mitigado ajustando a alocação de threads no Whisper e documentando a necessidade de paciência do usuário devido ao uso de CPU.

Visual Identity

All UI changes must strictly follow UI_GUIDELINES.md ensuring the Coherence visual identity guidelines (Clean Light Glassmorphism).